Tim Peko WS 2025/26

# **SWE3 - Übung 2** WS 2025/26

## Tim Peko

# Inhaltsverzeichnis

1.	Auf	fgabe: Merge Sort	2
		Lösungsidee	
		1.1.1. Merge Sort	
		1.1.1.1. Eigenschaften	
		1.1.2. Implementierung In-Memory	3
		1.1.2.1. Buffer Interfaces	3
		1.1.2.2. Kernlogik	4
		1.1.2.3. stream_reader Fixes	
		1.1.2.4. File Handling	
		1.1.2.5. In-Memory Buffers	
		1.1.2.6. Zusammenfügen	
	1.2.	Testfälle	10
		1.2.1. Liste der abgedeckten Testfälle	10
	1.3.	Ergebnisse	11
2.	Auf	fgabe: On Disk	11
	2.1.	Anforderungen	11
	2.2.	Lösungsidee	12
		2.2.1. Kleine Optimierung	12
		2.2.2. Validierung und Fehlerbehandlung	12
		2.2.3. On-Disk Buffers	
	2.3.	Tests	13
		Ergebnisse	
	4.4.	LIGODIII DO	

## 1. Aufgabe: Merge Sort

## 1.1. Lösungsidee

#### 1.1.1. Merge Sort

Der Merge Sort Algorithmus funktioniert, indem wir immer sortierte Subarrays zu einem sortierten Superarray zusammenfügen. Dazu machen wir uns die sortierte Eigenschaft zu Nutze und fügen immer das kleinste Element des linken und rechten Subarrays zu dem Superarray hinzu. Dieser Vorgang wird in Abbildung 1 demonstriert. Wichtig ist hierbei, dass ein zusätzlicher Buffer benötigt wird, der das gemerged Superarray speichert.

Um die gesamte Collection zu sortieren, brechen wir die Collection auf die kleinste möglichen Subarrays, die bereits sortiert sind, auf. Das sind die Subarrays, die nur ein Element enthalten. Danach wird der Merge Schritt für die immer größer werdenden (gemerged) Super-/Subarrays wiederholt, bis die gesamte Collection sortiert ist. Das ist in Abbildung 2 visualisiert.

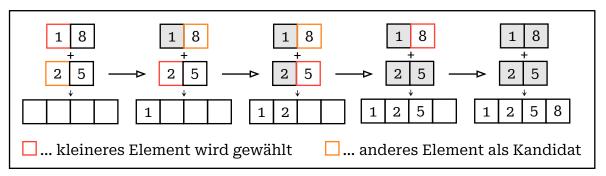


Abbildung 1: Visualisierung eines Merge Schrittes




Abbildung 2: Visualisierung des Merge Sort Algorithmus

#### 1.1.1.1. Eigenschaften

Der Merge Sort Algorithmus ist

• ein stabiler Sortieralgorithmus, da er die relative Reihenfolge der Elemente mit gleichem Wert beibehält.

- kein in-place Sortieralgorithmus, da er zusätzlichen Speicher benötigt.
- ein vergleichsbasierter Sortieralgorithmus, da er nur auf Vergleichsoperatoren basiert.
- gut in Dateien aufteilbar, da er die Daten in kleinere Chunks aufteilt, die separat sortiert werden können.
- mit einer Zeitkomplexität von  $O(n \log n)$  im besten, durchschnittlichen und schlechtesten Fall.
- mit einer Platzkomplexität von O(n) für den zusätzlichen Speicher.




Abbildung 3: Komplexität des Merge Sort Algorithmus

#### 1.1.2. Implementierung In-Memory

Es existiert eine main.cpp Datei, die allerdings nur eine Dummy Main Funktion enthält. Sie dient lediglich dazu, das Projekt kompilieren zu können. Alternativ könnte in Visual Studio auch der Projekttyp auf Static Library gesetzt werden. Das wird hier zur leichteren Kompatibilität nicht gemacht.

#### 1.1.2.1. Buffer Interfaces

Da in Abschnitt 2 auf die On-Disk Sortierung eingegangen wird, habe ich einen Merge Sort implementiert, der es uns erlaubt, einfach per Interface die Buffer Typen (In-Memory oder On-Disk) zu wechseln:

```
// merge_sort.hpp

// Generic interface for reading elements in merge operations.

template<typename T>
class IMergeReader {
public:
    virtual ~IMergeReader() = default;

/// Returns the current value at the reader's position.
    virtual T get() = 0;
```

```
/// Advances the reader to the next value.
      virtual bool advance() = 0;
      /// Checks if the reader is advanced to exhaustion.
      virtual bool is_exhausted() = 0;
      /// Converts this reader into an IMergeWriter, allowing the buffer to be reused
 for writing.
      virtual std::unique_ptr<IMergeWriter<T>> into_writer() = 0;
20 };
22 /// Generic interface for writing (appending) elements in merge operations.
23 template<typename T>
24 class IMergeWriter {
25 public:
      virtual ~IMergeWriter() = default;
      /// Appends a value at the writer's position.
      virtual bool append(const T& value) = 0;
      /// Converts this writer into an IMergeReader, allowing the written data to be
 read.
      virtual std::unique_ptr<IMergeReader<T>> into_reader() = 0;
```

#### 1.1.2.2. Kernlogik

Der Kern der Merge Sort Implementierung ist die merge\_step Methode, die zwei Subarrays merged und in einen Zielbuffer schreibt. Das ist in Abbildung 1 visualisiert. Chunksize ist dabei die Größe der bereits gemergeden und damit sortierten Subarrays.

```
срр
1 template <typename T>
bool merge_sorter::merge_step(IMergeReader<T> &reader_l, IMergeReader<T> &reader_r,
  IMergeWriter<T> &writer, size_t chunk_size_per_reader)
      size_t l_merged_count = 0; // Increment until chunk_size is reached
      size_t r_merged_count = 0; // Increment until chunk_size is reached
      bool l_exhausted = reader_l.is_exhausted();
      bool r_exhausted = reader_r.is_exhausted();
      // Zip and merge one chunk of size chunk_size_per_reader
      while (l_merged_count < chunk_size_per_reader && r_merged_count <
  chunk_size_per_reader && !l_exhausted && !r_exhausted)
      {
          T left_val = reader_l.get();
          T right_val = reader_r.get();
          if (left_val ≤ right_val)
              writer.append(left_val);
              l_exhausted = !reader_l.advance();
              l_merged_count++;
          }
          else
          {
              writer.append(right_val);
              r_exhausted = !reader_r.advance();
              r_merged_count++;
      }
28
      // Finish remaining elements from left reader for this chunk
      while (l_merged_count < chunk_size_per_reader && !l_exhausted)</pre>
```

In Vorbereitung auf On-Disk Sortierung, alterniert die merge Methode für jeden Teilchunk zwischen zwei Zielbuffern. Abbildung 4 visualisiert diesen Vorgang.

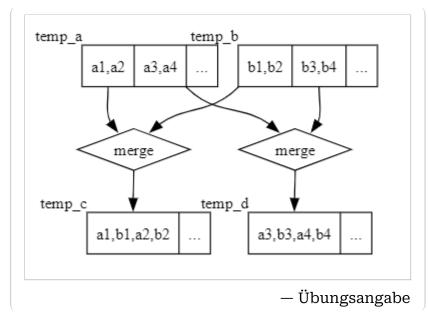


Abbildung 4: Jeweils Chunks der Größe n von A und B, werden zu einem Chunk der Größe 2n zusammengeführt. Die neuen Chunks werden abgechselnd in C und D geschrieben.

Diese Schritter werden in der sort Methode so oft wiederholt und zwischen Quell- und Zielbuffern alterniert, bis die gesamte Collection sortiert ist. Dabei ist hier der finale merge Schritt noch ausständig.

```
срр
  template <typename T>
  void merge_sorter::sort(
      std::unique_ptr<IMergeReader<T>> &reader_l, ... &reader_r,
      std::unique_ptr<IMergeWriter<T>> &writer_l, ... &writer_r,
      size_t total_size)
      size_t chunk_size = 1;
      while (true)
          merge(*reader_l, *reader_r, *writer_l, *writer_r, chunk_size);
          chunk_size *= 2;
          if (chunk_size ≥ total_size)
               // We have finished the last iteration and writers contain sorted data
              break;
          }
          // Prepare next chunk sized merge run
          // Swap reader and writer buffer roles
      }
22 }
```

Zusätzlich gibt es noch die Hilfsmethode split, die alternierend die Elemente der unsortierten Collection in zwei Hälften schreibt.

Die complete\_sort Methode

- 1. Splittet die unsortierte Collection in zwei Hälften
- 2. Führt den finalen Merge Schritt aus
- 3. Setzt den Quellbuffer auf den neuen sortierten Buffer

Visualisierung in Abbildung 5.

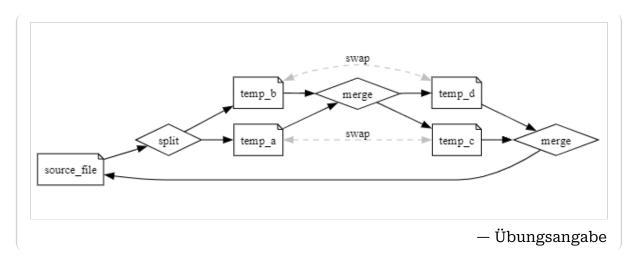


Abbildung 5: Flowchart der complete\_sort Methode: Aufteilung und wiederholtes zusammenführen von immer größeren Chunks.

```
template <typename T>
void merge_sorter::complete_sort(
std::unique_ptr<IMergeReader<T>> &unsorted_source,
std::unique_ptr<IMergeWriter<T>> buffer1, ... buffer4)
```

```
// Split the unsorted source into two halves
auto total_size = split(*unsorted_source, *buffer1, *buffer2);

// Sort the two halves
auto reader_l = buffer1→into_reader();
auto reader_r = buffer2→into_reader();
sort<T>(reader_l, reader_r, buffer3, buffer4, total_size);

// Merge the two sorted halves into the soure
auto sorted_l = buffer3→into_reader();
auto sorted_r = buffer4→into_reader();
auto sorted_full = unsorted_source→into_writer();
merge_step<T>(*sorted_l, *sorted_r, *sorted_full, total_size);

// re-seat the source ⇒ reset the cursor to 0
unsorted_source = sorted_full→into_reader();

// self-control of the source of the cursor to 0
unsorted_source = sorted_full→into_reader();
```

#### 1.1.2.3. stream\_reader Fixes

Die per Moodle offiziell bereitgestellte stream\_reader Klasse zeigt unerwartetes Verhalten bei der Verwendung: Die interne Methode stream\_reader::next() gibt am Ende des Filestreams einen leeren String "" zurück. Das liegt an der Implementierung der stream\_reader::has\_next() Methode:

```
template<typename T>
inline bool stream_reader<T>::has_next() {
   return buffer.has_value() || (m_in && m_in.good() && !m_in.eof());
}
```

Diese spiegelt nämlich die Implementierung des std::istream::operator >> wider und daher wird bei stream\_reader::next() versucht, ein neues T auszugeben, was am Ende des Streams fehlschlägt und einen leer initialisierten String zurückgibt.

Die Lösung wird durch einen Buffer implementiert:

```
cpp
1 template<typename T>
inline bool stream_reader<T>::has_next() {
     if (buffer) return true;
      T tmp;
                                   // only true when a token was actually read
      if (m_in >> tmp) {
          buffer = std::move(tmp); // stash it for next()
          return true;
      }
8
9
      return false;
10 }
12 template<typename T>
inline std::optional<T> stream_reader<T>::next() {
     if (buffer) {
         auto v = std::move(*buffer);
         buffer.reset();
         return v;
     }
     T tmp;
     if (m_in >> tmp) return tmp; // succeed \rightarrow return token
                            // fail → no token
      return std::nullopt;
22 }
```

#### 1.1.2.4. File Handling

Dateien werden mittels der stream\_reader Klasse gelesen. Folgender Code wird dazu im Projekt verwendet:

```
std::ifstream read_file(file_name);
stream_reader<std::string> reader(read_file);
std::vector<std::string> data;
while (reader.has_next())
{
    data.push_back(reader.get());
}
read_file.close();
```

Dateien werden folgendermaßen mit neuer Datenfolge beschrieben:

```
std::ofstream write_file(file_name);
for (const auto &entry : data)
{
    write_file << entry << " ";
}
write_file.close();</pre>
```

#### 1.1.2.5. In-Memory Buffers

Die InMemoryReader und InMemoryWriter Klassen werden verwendet, um In-Memory Datenfolgen zu lesen und zu schreiben. Sie verwenden einen std::vector<T> als Datenquelle und schreiben in diesen.

Die Reader haben einen Cursor, der auf das aktuelle Element zeigt und bei jedem Aufruf von advance() um eins erhöht wird. Bei einer Konvertierung zu einem Writer, wird der backing Vector geleert und per shared\_ptr an den entstehenden Writer übergeben.

Wird der Writer zurück in einen Reader konvertiert, wird der Cursor auf 0 gesetzt und der backing Vector ebenfalls per shared\_ptr an den entstehenden Reader übergeben.

```
template<typename T>
class InMemoryReader : public IMergeReader<T> {
  private:
    std::shared_ptr<std::vector<T>> _data;
    size_t _cursor;

public:
    explicit InMemoryReader(std::shared_ptr<std::vector<T>> data, size_t cursor = 0)
    : _data(data), _cursor(cursor) {}

I get() override {
    if (is_exhausted()) {
        throw std::underflow_error("No more elements to read");
    }
    return (*_data)[_cursor];
}

bool advance() override {
    if (is_exhausted()) {
        return false;
    }
    _cursor++;
```

```
// Return true if we can further advance once more
          return _cursor < _data→size();</pre>
      }
      bool is_exhausted() override {
          return _cursor ≥ _data→size();
      std::unique_ptr<IMergeWriter<T>> into_writer() override {
          _data→clear();
          return std::make_unique<InMemoryWriter<T>>(_data);
      }
35 };
37 template<typename T>
38 class InMemoryWriter : public IMergeWriter<T> {
      std::shared_ptr<std::vector<T>> _data;
42 public:
      explicit InMemoryWriter(std::shared_ptr<std::vector<T>> data = nullptr)
          : _data(data ? data : std::make_shared<std::vector<T>>()) {}
      bool append(const T& value) override {
          _data→push_back(value);
          return true;
      std::unique_ptr<IMergeReader<T>> into_reader() override {
          return std::make_unique<InMemoryReader<T>>(_data, 0);
54 };
```

#### 1.1.2.6. Zusammenfügen

Die komplette In-Memory Sortierung wird in der sort\_vec\_in\_memory Methode zusammengeführt. Die sort\_file\_in\_memory Methode liest mit den in Abschnitt 1.1.2.4 gezeigten Methoden die Datei in einen std::vector<std::string> und führt dann die Sortierung mit sort\_vec\_in\_memory durch, bevor sie die sortierte Datenfolge wieder in die Datei schreibt.

```
срр
  void merge_sorter::sort_vec_in_memory(std::vector<std::string> &data)
      std::unique_ptr<IMergeReader<std::string>> input_reader(
        std::make_unique<InMemoryReader<std::string>>(
          std::make_shared<std::vector<std::string>>(data)
      );
      complete_sort<std::string>(
          input_reader,
          std::make_unique<InMemoryWriter<std::string>>(),
      // Write the data from input_reader back to data vector
      data.clear():
      while (!input_reader→is_exhausted())
          data.push_back(input_reader→get());
          input_reader → advance();
      }
20
21 }
```

#### 1.2. Testfälle

Der Standard-Testfall

1. Arrange - Legt eine Datei mit zufälligen Strings an

```
std::string filename = "test_file.txt";
file_manipulator::fill_randomly(filename, array_length, string_length);
```

2. Act - Sortiert diese per merge\_sorter::sort\_file\_in\_memory(...)

```
merge_sorter sorter;
sorter.sort_file_in_memory(filename);
```

3. Assert - Verifiziert das Ergebnis hinsichtlich der Sortierung.

```
std::ifstream file(filename);
stream_reader<std::string> reader(file);

std::string prev = reader.get();
while (reader.has_next()) {
    std::string current = reader.get();
    ASSERT_LE(prev, current) << "Elements are not in sorted order";
    prev = current;
}</pre>
```

#### 1.2.1. Liste der abgedeckten Testfälle

Die folgenden Testfälle überprüfen die merge\_sorter Implementierung:

- Default Testfall Parametrisiert
  - String Länge 2, 10, 20
  - Array Länge 10, 200, 5000, 100000
- · Leere Datei
- Verkehrt sortierte Datei
- · Datei mit Duplikaten
- Datei mit unterschiedlich langen Strings

Zusätzlich gibt es kleine Testfälle, die sowohl die random.h als auch die stream\_reader.h Implementierung testen.

#### 1.3. Ergebnisse




Abbildung 6: Ergebnisse der Testfälle für Beispiel 1

Alle Testfälle bestehen erfolgreich, wie in Abbildung 6 zu sehen ist. Es fällt auf, dass die Laufzeit bei den parametrisierten Testfällen stark unterschiedlich ausfällt. Das liegt an der stark unterschiedlichen Größe der zu sortierenden Datei.

## 2. Aufgabe: On Disk

## 2.1. Anforderungen

Wir müssen folgende Anforderungen aus der Angabe erfüllen:

Ein paar Implementierungshinweise:

- 1. Die Klasse merge\_sorter soll die in der Übung besprochene Klasse file\_manipulator für alle Dateioperationen verwenden. Diese Dateioperationen könnten sein: eine Datei kopieren, eine Datei mit Zufallswerten füllen, eine Datei in mehrere Dateien aufsplitten, den Inhalt einer Datei ausgeben.
- 2. Die Klasse file\_manipulator operiert auf ifstreams und ofstreams. Die einzigen erlaubten Operationen auf diese Streams sind nur « und ».
- 3. Die Klasse stream\_reader<value\_type> ...

Übungsangabe

### 2.2. Lösungsidee

Prinzipiell müssen nur noch die IMergeReader und IMergeWriter Interfaces für On-Disk implementiert werden. Um auch die Anforderungen zu erfüllen, nutzen wir dazu eine file\_manipulator Klasse, die folgende statische Methoden bereitstellt:

- 1. fill\_randomly(std::string const& file\_name, size\_type n = 100, size\_type len = 4):
   Füllt eine Datei mit Zufallswerten.
- 2. append(std::ofstream& file, std::string const& str): Fügt eine Zeichenkette an die Datei an.
- 3. print(std::string const& src\_file\_name, std::ostream& out = std::cout): Gibt den Inhalt der Datei auf die Konsole aus.
- 4. delete\_file(std::string const& file\_name): Löscht eine Datei.

#### 2.2.1. Kleine Optimierung

In der merge\_sorter::sort(...) Methode können wir die Iteration früher abbrechen, als wir in Abschnitt 1 implementiert haben. Dazu verwenden wir die chunk\_size > total\_size / 2 Bedingung statt chunk\_size > total\_size. Das liegt daran, dass wir nur den Inhalt der beiden Writer, die jeweils die Hälfte der Daten entsprechen, sortieren müssen. Der letzte Merge Schritt wird dann über den finalen merge\_sorter::merge(...) Aufruf in merge\_sorter::complete\_sort(...) durchgeführt.

#### 2.2.2. Validierung und Fehlerbehandlung

- Öffnen einer Datei wird geprüft; bei Fehlern werden aussagekräftige Exceptions geworfen (z. B. in FileMergeReader/-Writer, merge\_sorter::sort\_file\_in\_memory).
- Lesen/Writing geschieht nur über <//>
  </>> (Anforderung 2); Formatfehler führen zu has\_next()=false und werden nicht stillschweigend als leere Tokens interpretiert.

#### 2.2.3. On-Disk Buffers

Die On-Disk Implementierung erfolgt über zwei Klassen in file\_merge\_buffer.cpp:

- FileMergeReader<T>: Implementiert IMergeReader<T> für das Lesen aus Dateien. Nutzt intern stream\_reader<T> und std::ifstream. Beim Öffnen wird geprüft, ob die Datei existiert - andernfalls wird eine std::runtime\_error Exception geworfen.
- FileMergeWriter<T>: Implementiert IMergeWriter<T> für das Schreiben in Dateien. Nutzt std::ofstream und die file\_manipulator::append() Methode. Beim Erstellen wird die Zieldatei geleert, um saubere Ausgangsbedingungen zu schaffen.

Beide Klassen unterstützen die into\_reader()/into\_writer() Konvertierung, die für das Wechseln zwischen Lese- und Schreibmodus auf derselben Datei erforderlich ist. Dies ermöglicht es, dass die Buffer-Dateien sowohl als Eingabe als auch als Ausgabe in verschiedenen Phasen des Merge-Sort-Algorithmus verwendet werden können.

```
срр
1 template<typename T>
class FileMergeReader : public IMergeReader<T> {
      std::string _filename;
      std::unique_ptr<stream_reader<T>> _reader;
      std::unique_ptr<std::ifstream> _file;
  public:
      T get() override {
          if (is_exhausted()) {
              throw std::underflow_error("No more elements to read");
          return _reader→peek();
      }
      bool advance() override {
          if (is_exhausted()) {
              return false;
          _reader→get(); // consume current element
          return _reader→has_next();
      }
      bool is_exhausted() override {
          return !_reader→has_next();
27 };
29 template<typename T>
30 class FileMergeWriter : public IMergeWriter<T> {
31 private:
      std::string _filename;
      std::unique_ptr<std::ofstream> _file;
34 public:
      bool append(const T& value) override {
          if (!_file→is_open()) {
              return false;
          file_manipulator::append(*_file, value);
          return true;
      }
42 };
```

#### **2.3. Tests**

Wir setzen auch in diesem Beispiel auf den etablierten Standard-Testfall aus Abschnitt 1.2. Dabei werden die Testfälle für On-Disk Sortierung hinzugefügt. Wir erzeugen beim Testfall string\_length = 100 und array\_length = 1000000 eine Datei mit knapp unter 100 MB Daten. Mit dem zusätzlichen Speichervorbauch der vier Buffer sind das insgesamt ~300 MB Speicher.

Zusätzlich testen wir die Fehlerbehandlung für nicht vorhandene Dateien:

```
TEST(MergeSortTest, TestNonexistentFileOnDiskThrows) {
    // Arrange
    std::string filename = "__no_such_file_exists__.txt";
    remove(filename.c_str());

// Act + Assert
    merge_sorter sorter;
    ASSERT_THROW(sorter.sort_file_on_disk(filename), std::runtime_error);
}
```

#### 2.4. Ergebnisse

Die Tests verifizieren die korrekte Sortierung und robuste Fehlerbehandlung. Auch hier zeigt Abbildung 7, dass die Laufzeit entsprechend mit der Größe der zu sortierenden Datenfolge wächst. Der Testlauf, der die 100 MB Datei sortiert, dauert ~10 Minuten. Die Struktur mit IMergeReader/IMergeWriter ermöglicht identische Kernlogik für In-Memory und On-Disk, was die Wartbarkeit verbessert.




Abbildung 7: Ergebnisse der Testfälle für Beispiel 2