

SWE3 - Übung 2

WS 2025/26

Tim Peko

Inhaltsverzeichnis

1. Aufgabe: Merge Sort	2
1.1. Lösungsidee	2
1.1.1. Merge Sort	2
1.1.2. Implementierung In-Memory	2
1.1.2.1. Buffer Interfaces	3
1.1.2.2. Kernlogik	3
1.1.2.3. stream_reader Fixes	5
1.1.2.4. File Handling	6
1.1.2.5. In-Memory Buffers	6
1.1.2.6. Zusammenfügen	7
1.2. Testfälle	8
1.2.1. Liste der abgedeckten Testfälle	8
1.3. Ergebnisse	9
2. Aufgabe: On Disk	9
2.1. Lösungsidee	9
2.2. Ergebnisse	9
2.3. Testfälle	9

1. Aufgabe: Merge Sort

1.1. Lösungsidee

1.1.1. Merge Sort

Der Merge Sort Algorithmus funktioniert, indem wir immer sortierte Subarrays zu einem sortierten Superarray zusammenfügen. Dazu machen wir uns die sortierte Eigenschaft zu Nutze und fügen immer das kleinste Element des linken und rechten Subarrays zu dem Superarray hinzu. Dieser Vorgang wird in Abbildung 1 demonstriert. Wichtig ist hierbei, dass ein zusätzlicher Buffer benötigt wird, der das gemerged Superarray speichert.

Um die gesamte Collection zu sortieren, brechen wir die Collection auf die kleinste möglichen Subarrays, die bereits sortiert sind, auf. Das sind die Subarrays, die nur ein Element enthalten. Danach wird der Merge Schritt für die immer größer werdenden (gemerged) Super-/Subarrays wiederholt, bis die gesamte Collection sortiert ist. Das ist in Abbildung 2 visualisiert.

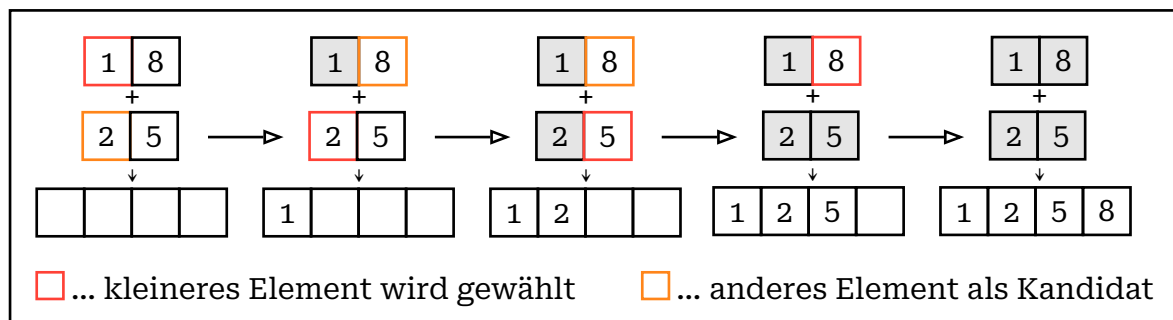


Abbildung 1: Visualisierung eines Merge Schrittes




Abbildung 2: Visualisierung des Merge Sort Algorithmus

1.1.2. Implementierung In-Memory

Es existiert eine `main.cpp` Datei, die allerdings nur eine Dummy Main Funktion enthält. Sie dient lediglich dazu, das Projekt kompilieren zu können. Alternativ

könnte in Visual Studio auch der Projekttyp auf Static Library gesetzt werden. Das wird hier zur leichteren Kompatibilität nicht gemacht.

1.1.2.1. Buffer Interfaces

Da in Abschnitt 2 auf die On-Disk Sortierung eingegangen wird, habe ich einen Merge Sort implementiert, der es uns erlaubt, einfach per Interface die Buffer Typen (In-Memory oder On-Disk) zu wechseln:

```
1. // merge_sort.hpp cpp
2.
3. /// Generic interface for reading elements in merge operations.
4. template<typename T>
5. class IMergeReader {
6. public:
7.     virtual ~IMergeReader() = default;
8.
9.     /// Returns the current value at the reader's position.
10.    virtual T get() = 0;
11.
12.    /// Advances the reader to the next value.
13.    virtual bool advance() = 0;
14.
15.    /// Checks if the reader is advanced to exhaustion.
16.    virtual bool is_exhausted() = 0;
17.
18.    /// Converts this reader into an IMergeWriter, allowing the buffer to be reused
    for writing.
19.    virtual std::unique_ptr<IMergeWriter<T>> into_writer() = 0;
20. };
21.
22. /// Generic interface for writing (appending) elements in merge operations.
23. template<typename T>
24. class IMergeWriter {
25. public:
26.     virtual ~IMergeWriter() = default;
27.
28.     /// Appends a value at the writer's position.
29.     virtual bool append(const T& value) = 0;
30.
31.    /// Converts this writer into an IMergeReader, allowing the written data to
    be read.
32.    virtual std::unique_ptr<IMergeReader<T>> into_reader() = 0;
33. };

```

1.1.2.2. Kernlogik

Der Kern der Merge Sort Implementierung ist die merge_step Methode, die zwei Subarrays merged und in einen Zielbuffer schreibt. Das ist in Abbildung 1 visualisiert. Chunksize ist dabei die Größe der bereits gemerged und damit sortierten Subarrays.

```
1. template <typename T> cpp
2. bool merge_sorter::merge_step(IMergeReader<T> &reader_l, IMergeReader<T> &reader_r,
    IMergeWriter<T> &writer, size_t chunk_size_per_reader)
3. {
4.     size_t l_merged_count = 0; // Increment until chunk size is reached
5.     size_t r_merged_count = 0; // Increment until chunk size is reached
6.     bool l_exhausted = reader_l.is_exhausted();
7.     bool r_exhausted = reader_r.is_exhausted();
8.
9.     // Zip and merge one chunk of size chunk size per reader
10.    while (l_merged_count < chunk_size_per_reader && r_merged_count <
        chunk_size_per_reader && !l_exhausted && !r_exhausted)
11.    {

```

```

12.     T left_val = reader_l.get();
13.     T right_val = reader_r.get();
14.
15.     if (left_val ≤ right_val)
16.     {
17.         writer.append(left_val);
18.         l_exhausted = !reader_l.advance();
19.         l_merged_count++;
20.     }
21.     else
22.     {
23.         writer.append(right_val);
24.         r_exhausted = !reader_r.advance();
25.         r_merged_count++;
26.     }
27. }
28.
29. // Finish remaining elements from left reader for this chunk
30. while (l_merged_count < chunk_size_per_reader && !l_exhausted)
31. {
32.     writer.append(reader_l.get());
33.     l_exhausted = !reader_l.advance();
34.     l_merged_count++;
35. }
36.
37. // Finish remaining elements from right reader for this chunk
38. ... // Same but for other side
39.
40. return !l_exhausted || !r_exhausted;
41. }

```

In Vorbereitung auf On-Disk Sortierung, alterniert die merge Methode für jeden Teilchunk zwischen zwei Zielbuffern.

```

1. template <typename T> cpp
2. void merge_sorter::merge(IMergeReader<T> &sorted_l, IMergeReader<T> &sorted_r,
3. IMergeWriter<T> &writer_l, IMergeWriter<T> &writer_r, size_t chunk_size)
4. {
5.     bool write_to_left = true; // Start with writer_l for first chunk
6.
7.     while (true)
8.     {
9.         IMergeWriter<T> &writer = write_to_left ? writer_l : writer_r;
10.        if (!merge_step(sorted_l, sorted_r, writer, chunk_size)) {
11.            break;
12.        }
13.
14.        // Switch to the other writer for the next chunk
15.        write_to_left = !write_to_left;
16.    }
17. }

```

Diese Schritte werden in der sort Methode so oft wiederholt und zwischen Quell- und Zielbuffern alterniert, bis die gesamte Collection sortiert ist. Dabei ist hier der finale merge Schritt noch ausständig.

```

1. template <typename T> cpp
2. void merge_sorter::sort(
3.     std::unique_ptr<IMergeReader<T>> &reader_l, ... &reader_r,
4.     std::unique_ptr<IMergeWriter<T>> &writer_l, ... &writer_r,
5.     size_t total_size)
6. {
7.     size_t chunk_size = 1;
8.     while (true)

```

```

9.     {
10.         merge(*reader_l, *reader_r, *writer_l, *writer_r, chunk_size);
11.         chunk_size *= 2;
12.         if (chunk_size > total_size)
13.         {
14.             // We have finished the last iteration and writers contain sorted data
15.             break;
16.         }
17.
18.         // Prepare next chunk sized merge run
19.         // Swap reader and writer buffer roles
20.         ...
21.     }
22. }

```

Zusätzlich gibt es noch die Hilfsmethode `split`, die alternierend die Elemente der unsortierten Collection in zwei Hälften schreibt.

Die `complete_sort` Methode

1. Splittet die unsortierte Collection in zwei Hälften
2. Führt den finalen Merge Schritt aus
3. Setzt den Quellbuffer auf den neuen sortierten Buffer

```

1. template<typename T>                                     cpp
2. void merge_sorter::complete_sort(
3.     std::unique_ptr<IMergeReader<T>> &unsorted_source,
4.     std::unique_ptr<IMergeWriter<T>> buffer1, ... buffer4)
5. {
6.     // Split the unsorted source into two halves
7.     auto total_size = split(*unsorted_source, *buffer1, *buffer2);
8.
9.     // Sort the two halves
10.    auto reader_l = buffer1->into_reader();
11.    auto reader_r = buffer2->into_reader();
12.    sort<T>(reader_l, reader_r, buffer3, buffer4, total_size);
13.
14.    // Merge the two sorted halves into the source
15.    auto sorted_l = buffer3->into_reader();
16.    auto sorted_r = buffer4->into_reader();
17.    auto sorted_full = unsorted_source->into_writer();
18.    merge_step<T>(*sorted_l, *sorted_r, *sorted_full, total_size);
19.
20.    // re-seat the source => reset the cursor to 0
21.    unsorted_source = sorted_full->into_reader();
22. }

```

1.1.2.3. stream_reader Fixes

Die per Moodle offiziell bereitgestellte `stream_reader` Klasse zeigt unerwartetes Verhalten bei der Verwendung: Die interne Methode `stream_reader::next()` gibt am Ende des Filestreams einen leeren String "" zurück. Das liegt an der Implementierung der `stream_reader::has_next()` Methode:

```

1. template<typename T>                                     cpp
2. inline bool stream_reader<T>::has_next() {
3.     return buffer.has_value() || (m_in && m_in.good() && !m_in.eof());
4. }

```

Diese spiegelt nämlich die Implementierung des `std::istream::operator >>` wider und daher wird bei `stream_reader::next()` versucht, ein neues `T` auszugeben, was am Ende des Streams fehlschlägt und einen leer initialisierten String zurückgibt.

Die Lösung wird durch einen Buffer implementiert:

```
1. template<typename T>
2. inline bool stream_reader<T>::has_next() {
3.     if (buffer) return true;
4.     T tmp;
5.     if (m_in >> tmp) { // only true when a token was actually read
6.         buffer = std::move(tmp); // stash it for next()
7.         return true;
8.     }
9.     return false;
10. }
11.
12. template<typename T>
13. inline std::optional<T> stream_reader<T>::next() {
14.     if (buffer) {
15.         auto v = std::move(*buffer);
16.         buffer.reset();
17.         return v;
18.     }
19.     T tmp;
20.     if (m_in >> tmp) return tmp; // succeed → return token
21.     return std::nullopt; // fail → no token
22. }
```

1.1.2.4. File Handling

Dateien werden mittels der `stream_reader` Klasse gelesen. Folgender Code wird dazu im Projekt verwendet:

```
1. std::ifstream read_file(file_name);
2. stream_reader<std::string> reader(read_file);
3. std::vector<std::string> data;
4. while (reader.has_next())
5. {
6.     data.push_back(reader.get());
7. }
8. read_file.close();
```

Dateien werden folgendermaßen mit neuer Datenfolge beschrieben:

```
1. std::ofstream write_file(file_name);
2. for (const auto &entry : data)
3. {
4.     write_file << entry << " ";
5. }
6. write_file.close();
```

1.1.2.5. In-Memory Buffers

Die `InMemoryReader` und `InMemoryWriter` Klassen werden verwendet, um In-Memory Datenfolgen zu lesen und zu schreiben. Sie verwenden einen `std::vector<T>` als Datenquelle und schreiben in diesen.

Die Reader haben einen Cursor, der auf das aktuelle Element zeigt und bei jedem Aufruf von `advance()` um eins erhöht wird. Bei einer Konvertierung zu einem Writer, wird der backing Vector geleert und per `shared_ptr` an den entstehenden Writer übergeben.

Wird der Writer zurück in einen Reader konvertiert, wird der Cursor auf 0 gesetzt und der backing Vector ebenfalls per shared_ptr an den entstehenden Reader übergeben.

```

1. template<typename T>                                     cpp
2. class InMemoryReader : public IMergeReader<T> {
3. private:
4.     std::shared_ptr<std::vector<T>> _data;
5.     size_t _cursor;
6.
7. public:
8.     explicit InMemoryReader(std::shared_ptr<std::vector<T>> data, size_t cursor = 0)
9.         : _data(data), _cursor(cursor) {}
10.
11.     T get() override {
12.         if (is_exhausted()) {
13.             throw std::underflow_error("No more elements to read");
14.         }
15.         return (*_data)[_cursor];
16.     }
17.
18.     bool advance() override {
19.         if (is_exhausted()) {
20.             return false;
21.         }
22.         _cursor++;
23.         // Return true if we can further advance once more
24.         return _cursor < _data->size();
25.     }
26.
27.     bool is_exhausted() override {
28.         return _cursor > _data->size();
29.     }
30.
31.     std::unique_ptr<IMergeWriter<T>> into_writer() override {
32.         _data->clear();
33.         return std::make_unique<InMemoryWriter<T>>(_data);
34.     }
35. };
36.
37. template<typename T>
38. class InMemoryWriter : public IMergeWriter<T> {
39. private:
40.     std::shared_ptr<std::vector<T>> _data;
41.
42. public:
43.     explicit InMemoryWriter(std::shared_ptr<std::vector<T>> data = nullptr)
44.         : _data(data ? data : std::make_shared<std::vector<T>>()) {}
45.
46.     bool append(const T& value) override {
47.         _data->push_back(value);
48.         return true;
49.     }
50.
51.     std::unique_ptr<IMergeReader<T>> into_reader() override {
52.         return std::make_unique<InMemoryReader<T>>(_data, 0);
53.     }
54. };

```

1.1.2.6. Zusammenfügen

```

1. void merge_sorter::sort_vec_in_memory(std::vector<std::string> &data)      cpp
2. {
3.     std::unique_ptr<IMergeReader<std::string>> input_reader(std::make_unique<InMemoryReader<std::string>>(s
4.
5.     complete_sort<std::string>(
6.         input_reader,
7.         std::make_unique<InMemoryWriter<std::string>>(),

```

```

8.     std::make_unique<InMemoryWriter<std::string>>(),
9.     std::make_unique<InMemoryWriter<std::string>>(),
10.    std::make_unique<InMemoryWriter<std::string>>());
11.
12.    // Write the data from input reader back to data vector
13.    data.clear();
14.    while (!input_reader->is_exhausted())
15.    {
16.        data.push_back(input_reader->get());
17.        input_reader->advance();
18.    }
19. }

```

1.2. Testfälle

Der Standard-Testfall

1. **Arrange** - Legt eine Datei mit zufälligen Strings an

```

1. std::string filename = "test_file.txt";
2. file_manipulator::fill_randomly(filename, array_length, string_length);

```

2. **Act** - Sortiert diese per `merge_sorter::sort_file_in_memory(...)` und verifiziert das Ergebnis hinsichtlich der Sortierung

```

1. merge_sorter sorter;
2. sorter.sort_file_in_memory(filename);

```

3. **Assert** - Verifiziert das Ergebnis hinsichtlich der Sortierung.

```

1. std::ifstream file(filename);
2. stream_reader<std::string> reader(file);
3.
4. std::string prev = reader.get();
5. while (reader.has_next()) {
6.     std::string current = reader.get();
7.     ASSERT_IF(prev, current) << "Elements are not in sorted order";
8.     prev = current;
9. }

```

1.2.1. Liste der abgedeckten Testfälle

Die folgenden Testfälle überprüfen die `merge_sorter` Implementierung:

- Default Testfall - *Parametrisiert*
 - String Länge 2, 10, 20
 - Array Länge 10, 200, 5000, 100000
- Leere Datei
- Verkehrt sortierte Datei
- Datei mit Duplikaten
- Datei mit unterschiedlich langen Strings

Zusätzlich gibt es kleine Testfälle, die sowohl die `random.h` als auch die `stream_reader.h` Implementierung testen.

1.3. Ergebnisse

Test run finished: 20 Tests (20 Passed, 0 Failed, 0 Skipped) run in 20 sec

Test	Duration
01_Beispiel_Test (20)	18,8 sec
<Empty Namespace> (20)	18,8 sec
MergeSortTest (5)	1 sec
TestEmptyFile	1 ms
TestFileWithDifferentStringLengths	910 ms
TestFileWithDuplicates	30 ms
TestFileWithNotOnlyAlphabetic	52 ms
TestReverseSortedFile	7 ms
ParameterizedTests/MergeSorterTest (12)	17,8 sec
TestSortInMemoryParameterized/0 [(2, 10)]	53 ms
TestSortInMemoryParameterized/1 [(2, 200)]	97 ms
TestSortInMemoryParameterized/10 [(20, 5000)]	448 ms
TestSortInMemoryParameterized/11 [(20, 100000)]	7 sec
TestSortInMemoryParameterized/2 [(2, 5000)]	348 ms
TestSortInMemoryParameterized/3 [(2, 100000)]	4,4 sec
TestSortInMemoryParameterized/4 [(10, 10)]	87 ms
TestSortInMemoryParameterized/5 [(10, 200)]	214 ms
TestSortInMemoryParameterized/6 [(10, 5000)]	351 ms
TestSortInMemoryParameterized/7 [(10, 100000)]	4,6 sec
TestSortInMemoryParameterized/8 [(20, 10)]	63 ms
TestSortInMemoryParameterized/9 [(20, 200)]	106 ms
RandomTest (2)	< 1 ms
StreamReaderTest (1)	< 1 ms

Abbildung 3: Ergebnisse der Testfälle für Beispiel 1

Alle Testfälle bestehen erfolgreich, wie in Abbildung 3 zu sehen ist. Es fällt auf, dass die Laufzeit bei den parametrisierten Testfällen stark unterschiedlich ausfällt. Das liegt an der stark unterschiedlichen Größe der zu sortierenden Datei.

2. Aufgabe: On Disk

2.1. Lösungsidee

2.2. Ergebnisse

2.3. Testfälle

Aufwand in h: 12